

《机器人学》大作业 3（拓展任务）

徐恺阳 523030910085

引言

大作业 3（拓展任务）包含以下内容：

- 使用仿真环境 `pybullet` 完善抓取方块任务的仿真环境；
- 使用强化学习算法（SAC），完成抓取方块任务的操作策略的训练和优化；
- 机械臂夹爪距离目标物体的距离小于阈值（0.01m），则视为任务成功。

任务一

任务描述

在 `panda_env.py` 中，完善仿真环境中的奖励函数。

提示：可以考虑以下几个方向

- 靠近奖励：目标方块和夹爪的距离越近，奖励越大；
- 姿态奖励：夹爪姿态与期望抓取姿态的差越小，奖励越大；
- 到达奖励：当目标方块和夹爪的距离小于目标阈值时，给予固定奖励。

任务实现

`_get_reward` 函数中：

- 靠近奖励
 - 目标方块和夹爪的距离越近，奖励越大；
 - 引导机械臂靠近目标物体。

```
r_reaching = -10 * ee_to_object_dist
```

- 姿态奖励
 - 夹爪朝向与期望抓取朝向的差越小，奖励越大；

- 引导机械臂以正确的姿态抓取目标物体。

```
angle_difference = self.angle_diff(ee_quat, grasp_pose[3:])  
r_quat = -1 * angle_difference
```

3. 到达奖励

- 当目标方块和夹爪的距离小于目标阈值时，给予固定奖励；
- 作为一个稀疏的成功信号，强化机械臂最终到达目标物体的行为。

```
if ee_to_object_dist < 0.01:  
    r_arrival = 10
```

4. 总奖励

```
reward = r_reaching + r_quat + r_arrival
```

任务二

任务描述

定义动作空间和观测空间。

任务实现

1. 动作空间

- 连续空间：机械臂 5 个关节角度增量

```
self.action_space = spaces.Box(low=-1, high=1, shape=(5,), dtype=np.float32)
```

2. 观测空间

- 连续空间
 - 机械臂关节角度 **qpos**: 6 维（5 维机械臂关节 + 1 维夹爪）；
 - 机械臂夹爪位姿 **ee_pose**: 7 维（3 维位置 + 4 维四元数）；

- 目标抓取位姿 `grasp_pose`: 7 维 (3 维位置 + 4 维四元数)。

```
self.observation_space = spaces.Box(low=-np.inf, high=np.inf, shape=(20,), dtype=np.float32)
```

3. 获取观测

- `qpos` 和 `eepose` 通过 `dofbot` 类获取;
- `grasp_pose` 通过对物体位姿进行旋转变换得到:
 - 获取物体在世界坐标系下的位姿;
 - 将物体姿态沿 X 轴旋转 180 度, 以获得适合机械臂抓取的期望位姿。

```
obj_pos, obj_orn, obj_euler = self._object1.pos_and_orn()
obj_pose = np.concatenate([obj_pos, obj_orn])
grasp_pose = self.rotate2grasp_pose(obj_pose)
Observation["grasp_pose"] = grasp_pose
```

任务三

任务描述

在任务二的基础上完善 `step` 函数, 根据输入动作下发机械臂控制指令。

利用 `test_gym.py` 验证动作的可行性。

提示: 注意动作空间的范围, 要转换为真实的机械臂关节位置变化量的大小。

任务实现

1. 限制动作范围

- 将输入的动作限制在 `[-1, 1]` 范围内。

```
action = np.clip(action, self.action_space.low, self.action_space.high)
```

2. 将归一化的动作转换为实际的关节角度增量

```
scale = 0.05
dqpos = action * scale
```

3. 执行动作

- 调用 `self._dofbot.joint_control(dqpos)` 函数；
- 接收关节角度增量，进行关节位置控制（不包括夹爪）。

4. 仿真步进

- `pybullet` 执行物理步进 `p.stepSimulation()`。

5. 状态更新

- 返回当前观测值、奖励、是否终止、是否截断和额外信息。

```
return self._observation, reward, terminated, truncated, info
```

任务四

任务描述

通过求解逆运动学，找到逆运动学可解的位姿，放置方块。

任务实现

经大作业 1 任务 7 检验，`(0.18, 0.07, self.half_height)` 和 `(0.3, 0.12, self.half_height)` 均是 Dofbot 逆运动学可解的位置。

将物块重置在这两个位置，分别进行策略训练。

```
p.resetBasePositionAndOrientation(  
    self.id,  
    np.array([0.18, 0.07, self.half_height]),  
    p.getQuaternionFromEuler([0, 0, np.pi/6])  
)
```

任务五

任务描述

基于 SAC 算法，完成操作策略的训练，记录训练曲线，并测试效果。

任务实现

SAC 算法的核心流程如下：

1. 初始化

- 构建向量化环境 `SyncVectorEnv`;
- 初始化 Actor 网络、Critic 网络（双 Q 网络）与目标 Critic 网络;
- 创建经验回放池 `ReplayBuffer`。

2. 数据收集

- 使用 Actor 网络采样动作（包含探索噪声）;
- 与环境交互并将 `(s, a, r, s', done)` 存入经验回放池。

3. 网络更新

- 从经验回放池随机采样 batch 数据;
- Critic 更新:
 - 计算目标 Q 值: $y = r + \gamma(\min_{i=1,2} Q_{target,i}(s', a') - \alpha \log \pi(a'|s'))$;
 - 计算 Loss: $L_Q = \frac{1}{2} \sum_{i=1}^2 MSE(y, Q_i(s, a))$;
 - 反向传播更新 Critic 网络参数。
- Actor 更新:
 - 采样新动作 $\tilde{a}$ 和对数概率 $\log \pi(\tilde{a}|s)$;
 - 计算 Loss: $L_\pi = \alpha \log \pi(\tilde{a}|s) - \min_{i=1,2} Q_i(s, \tilde{a})$;
 - 反向传播更新 Actor 网络参数。
- Alpha 更新:
 - 自动调整熵系数 α 以维持目标熵。

4. 目标同步

- 使用软更新同步 Critic 网络参数到目标网络: $\theta_{target} \leftarrow \tau \theta + (1 - \tau) \theta_{target}$ 。

训练参数如下：

- `buffer_size=1_000_000`;
- `batch_size=256`;
- `gamma=0.99`;
- `policy_lr=3e-4`;
- `q_lr=1e-3`;
- `tau=0.005`;
- `alpha=0.2`;
- `total_timesteps=5_000_000`。

结果展示

正确绘制末端箭头与抓取点箭头，结果如下图所示。




图 1 末端位姿与抓取点位姿示意

以物块位置为 $(0.3, 0.12, \text{self.half_height})$ 的训练为例，训练曲线如图 2 和图 3 所示。




图 2 回合长度




图 3 回合回报

可以看出，随着训练的进行，

1. 回合长度最开始一直为 500，即允许的最大回合长度；
 - 说明机械臂完全无法完成任务，处于策略探索阶段。
2. 回合长度逐渐降低至 20 左右；
 - 说明机械臂可以很好地完成任务，使得 `termination` 的判断为 `true`，回合提前终止。
3. 回合回报逐渐上升至 -70 左右；
 - 说明机械臂在每个回合内获得的累积折扣奖励很多，回报很大。

测试 50 次策略效果，成功率为 100%，视频见 [results\record\20251201_175220.mp4](#) 和 [results\record\20251201_175330.mp4](#)。

结果分析

思考：为什么训练曲线会有很大的波动？有没有可以改进的地方？

答：SAC 是一种最大熵强化学习算法，其目标是同时最大化累积奖励和策略熵。这意味着 Agent 会在训练过程中保持较高的探索性。在尝试不同动作以探索环境时，可能会导致某些 Episode 的表现较差，从而引起曲线波动。

具体而言，刚开始的回合长度基本都是 500，只有极少部分回合长度小于 500，即回合提前终止，训练曲线体现出很大的波动。

改进方向

1. 目标物体重置位置固定，且在逆运动学可解处；
 - 尝试随机化重置目标物体的位置；
 - 引入课程学习，随着训练进行逐渐增加抓取的难度。
2. 优化奖励函数
 - 微调“接近奖励”和“姿态奖励”之间的权重平衡。
3. 引入 Hindsight Experience Replay (HER)
 - HER 针对目标导向任务，允许 Agent 从失败的尝试中学习，能显著解决稀疏奖励问题并提高样本效率。