

《机器人学》大作业 1

徐恺阳 523030910085

引言

大作业 1 包含以下内容：

1. 基于 **RobotToolboxPython** 工具完成 Dofbot 构型机械臂的建模、正运动学求解、逆运动学求解与工作空间的绘制；
2. 在 **PyBullet** 中，采集 Dofbot 机械臂末端位姿与关节角数据；
3. 训练神经网络模型，实现对机械臂正逆运动学的求解，并评估训练得到模型的精度；
4. 在 **PyBullet** 中，控制 Dofbot 机械臂完成物块抓取放置任务。

任务零：机械臂 DH 参数建模

任务描述

根据图 1 计算 Dofbot 机械臂的 DH 参数表，并使用 **RobotToolboxPython** 仿真正运动学，进行零位验证。




图 1 Dofbot 机械臂结构示意图

	α_{i-1}	a_{i-1}	θ_i	d_i
1	0	0	$0 + \varphi_1$	l_1
2	-90°	0	$-90^\circ + \varphi_2$	0
3	0	l_2	$0 + \varphi_3$	0
4	0	l_3	$90^\circ + \varphi_4$	0
5	90°	0	$0 + \varphi_5$	l_4

图 2 DH 参数表

任务实现

建立如图 2 所示的 坐标系，得出 DH 参数表，对 Dofbot 进行 DH 参数建模。

```
dofbot = rtb.DHRobot(  
    [  
        rtb.RevoluteMDH(a=0, alpha=0, d=l1, offset=0),  
        rtb.RevoluteMDH(a=0, alpha=-pi/2, d=0, offset=-pi/2),
```

```

rtb.RevoluteMDH(a=12, alpha=0, d=0, offset=0),
rtb.RevoluteMDH(a=13, alpha=0, d=0, offset=pi/2),
rtb.RevoluteMDH(a=0, alpha=pi/2, d=14, offset=0)
],
name="Dofbot"
)

```

结果展示

将全部关节置零，得到如图 3 所示的零位示意图。




图 3 零位示意图

任务一：正运动学求解

任务描述

给出 Dofbot 机械臂在特定关节角度下的正运动学解，并附上 [RobotToolboxPython](#) 给出的运动学姿态仿真。

任务实现

利用 `DHRobot` 类中的 `fkine` 和 `plot` 函数解正运动学，并实现运动学姿态仿真。

```

q_demo = [0., pi/3, pi/4, pi/5, 0.]
T_demo = dofbot.fkine(q_demo)
print(T_demo)
dofbot.plot(q=q_demo, block=True)

```

- `q_demo` 是关节角度的输入列表，包含了机械臂五个关节的角度；
- `dofbot.fkine(q_demo)` 是正运动学函数，返回一个变换矩阵，包含末端执行器的位置和姿态；

- `dofbot.plot(q=q_demo, block=True)` 可视化机械臂在给定关节角度下的姿态。

结果展示

```
===== Part1-0 (demo) 正解 =====
-0.7771    -1.686e-08    0.6293    0.2326
 1.686e-08    1          4.762e-08    5.58e-09
-0.6293    4.762e-08   -0.7771    0.02468
 0          0          0          1
```

```
===== Part1-1 (pose 1) 正解 =====
-1.983e-08    1          -9.592e-09    4.666e-09
 0.309        1.525e-08    0.9511    0.2496
 0.9511        1.589e-08   -0.309    0.1574
 0          0          0          1
```

```
===== Part1-2 (pose 2) 正解 =====
-0.866    -0.25    -0.433    -0.03704
 0.5       -0.433    -0.75     -0.06415
 3.66e-08  -0.866    0.5       0.3073
 0          0          0          1
```

```
===== Part1-3 (pose 3) 正解 =====
 0.866    0.5    0    -2.22e-09
-0.5      0.866    0    -2.22e-09
 0         0      1    0.3158
 0         0      0    1
```

图 4 正运动学解







图 5 运动学姿态仿真

任务二：逆运动学求解

任务描述

给出 Dofbot 机械臂夹爪末端在以下笛卡尔空间姿态下的逆运动学解，并在报告中附上 `RobotToolboxPython` 给出的运动学姿态仿真。

任务实现

利用 `DHRobot` 类中的 `ik_LM` 和 `plot` 函数解逆运动学，并实现运动学姿态仿真。

```
T_des_demo = np.array([
    [-1., 0., 0., 0.1],
    [ 0., 1., 0., 0. ],
```

```

[ 0., 0., -1., -0.1],
[ 0., 0., 0., 1. ]
])
q_ik_demo = dofbot.ik_LM(T_des_demo)[0] # 取返回元组第 0 个元素
print("关节角 (rad): ", np.array(q_ik_demo))
dofbot.plot(q=q_ik_demo, block=True)


```

- `T_des_demo` 是齐次变换矩阵，包含末端执行器的位置和姿态；
- `dofbot.ik_LM(T_des_demo)[0]` 使用 *Levenberg-Marquardt (LM)* 算法求解逆运动学。该函数返回一个元组，第一个元素是关节角度的解。

结果展示


===== Part2-0 (demo) 逆解 =====

关节角 (rad): [-4.12115191e-05 1.51096840e+00 1.42061495e+00 2.10009085e-4.12020419e-05]




===== Part2-1 (pose 1) 逆解 =====

关节角 (rad): [-1.53443132e-03 2.43655002e+00 1.22472094e-01 -2.55898320e+1.53627673e-03]



===== Part2-1 (pose 2) 逆解 =====

关节角 (rad): [-2.69998446 -0.69481863 0.57017888 -2.69595764 -1.8996055]



===== Part2-1 (pose 3) 逆解 =====

关节角 (rad): [-2.09439537 0.26233599 -1.04816952 1.83302808 -1.5708025]




图 6 逆运动学解

图 7 运动学姿态仿真

任务三：工作空间绘制

任务描述

按照关节空间针对每个关节进行采样，绘制机械臂工作空间。Dofbot 关节角度限位：

- J1: $[-180^\circ, 180^\circ]$
- J2: $[0^\circ, 180^\circ]$

- J3: $[0^\circ, 180^\circ]$
- J4: $[0^\circ, 180^\circ]$
- J5: $[0^\circ, 180^\circ]$

任务实现

```
num_samples = 3000

j1_min, j1_max = -np.pi, np.pi # J1
j_min, j_max = 0.0, np.pi # J2~J5

q1 = np.random.uniform(j1_min, j1_max, num_samples)
q2 = np.random.uniform(j_min, j_max, num_samples)
q3 = np.random.uniform(j_min, j_max, num_samples)
q4 = np.random.uniform(j_min, j_max, num_samples)
q5 = np.random.uniform(j_min, j_max, num_samples)
q_samples = np.vstack((q1, q2, q3, q4, q5)).T # 形状: (N, 5)

points = np.zeros((num_samples, 3), dtype=float)
for i in range(num_samples):
    T = dofbot.fkine(q_samples[i]) # SE3
    points[i] = T.t.reshape(3)
```

- `np.random.uniform` 在每个关节的上下限范围内生成 `num_samples` 个随机角度；
- 通过 `fkine` 函数求解正运动学，得到末端执行器的位置；
- 按 Z 高度着色绘制 `num_samples` 个工作点，并添加加颜色条。

结果展示

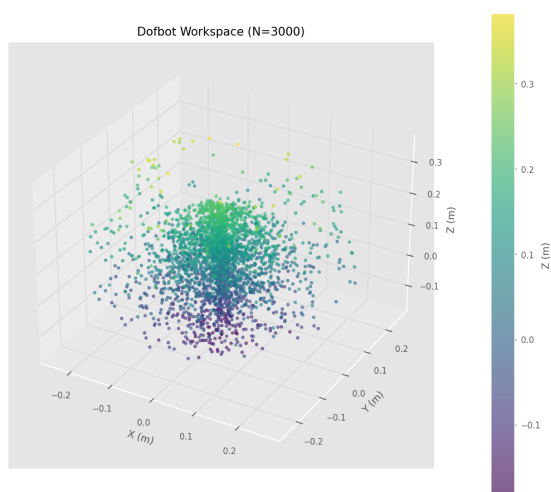


图 8 Dofbot 工作空间

从绘制结果可以看出，工作空间呈现出椭球状，且工作点出现在椭球中心以及椭球下方的数量居多。

任务四：数据采集与工作空间可视化

任务描述

在仿真环境中自行采集数据集，基于采集的数据集可视化工作空间。

任务实现

利用 `collect_dofbot_dataset` 函数进行仿真环境中的数据采集。

```
collect_dofbot_dataset(num_envs, num_samples, show_gui)
```

- `num_envs` 是并行环境数，默认为 2；
- `num_samples` 是总样本数，建议 10k 以上；
- `show_gui` 是否可视化数据采集过程。

详细步骤如下：

1. 启动并行 worker
 - 计算 `samples_per_worker`，并为每个 worker 指定写入分片；
 - 并行调用 `worker(rank, samples_per_worker, flush_every, run_tag)`。
2. 主进程流式合并与统计
 - 遍历每个分片文件，计算全局 `mins` 和 `maxs`；
 - 合并所有分片为 `raw_csv`，按分片顺序逐块复制内容；
 - 把全局 min/max 写到 `stats_json`。
3. 生成归一化文件 `norm_csv`
 - 打开 `raw_csv`，逐行读取原始 24 维向量并拆分为 `q_raw`, `xyz`, `quat`, `euler`, `dir_vec`；
 - 归一化：
 - `q_raw`: sin/cos 拼接 `sc_joint = [sin(q1),cos(q1),...,sin(q5),cos(q5)]`；
 - `xyz`: MinMax 到 `[-1,1]`；
 - `quat`: 保留原值；
 - `euler`: `[sin(roll),cos(roll),...,sin(yaw),cos(yaw)]`
 - `dir_vec`: 线性缩放到 `[-1,1]`
 - 组合并写入 `norm_csv`: `[sc_joint, xyz_n, quat, sc_euler, dir_n]`。
4. 返回
 - 返回三个路径 `raw_csv`, `norm_csv`, `stats_json`。

利用 `visualize_workspace` 函数进行工作空间的可视化，颜色按 Z 高度映射。

```
visualize_workspace(raw_csv)
```

- `raw_csv` 是原始 CSV 文件。

详细步骤如下：

1. 读取 `raw_csv`，并提取位置列
 - 读入所有行，并提取第 6~8 列，即 `xyz = data[:, 5:8]`。
2. 绘制 3D 散点图，并添加颜色条

结果展示




图 9 Dofbot 工作空间

从绘制结果可以看出，工作空间呈现出椭球状，且没有空洞，呈高度对称。

任务五：模型训练

任务描述

选择合适的神经网络结构，设置训练参数，基于采集/已有的数据集训练得到正逆运动学模型。

任务实现

利用 `train_dofbot_model` 函数选择神经网络结构，设置训练参数，训练正逆运动学模型。

```
train_dofbot_model(
    data_path, model_type, mode, in_cols, out_cols,
    epochs, lr, min_lr, hidden_layers
)
```

- **data_path** 是训练数据的路径;
- **model_type** 是网络模型;
- **mode** 是训练类型;
- **in_cols** 和 **out_cols** 是网络输入输出的数据和维度;
- **epochs** **lr** 和 **hidden_layers** 是训练超参数。

具体步骤如下:

1. 数据准备

- 使用已有的数据集 **dofbot_fk_120000_norm.csv**, 列顺序为:
 - 关节角 sin/cos (10 维)
 - 位置 xyz (3 维)
 - 四元数 abcd (4 维)
 - 欧拉角 sin/cos (6 维)
 - 方向向量归一化 (9 维)
- 对训练/测试数据做 80/20 划分。

2. 模型构造

- 使用 **FlexibleMLP**, 隐藏层选择 **[256,256,128]**, 其余均为默认配置。

3. 损失函数

- 记网络预测为 y_{pred} , 真实标签为 y_{true} , 输出位置为 $p \in \mathbb{R}^3$, 输出姿态为 $r \in \mathbb{R}^9$ 。
- FK 第一种损失函数:

- 位置误差 L_{pos}

$$L_{\text{pos}} = \|p_{\text{pred}} - p_{\text{true}}\|_2^2$$

- 姿态误差 L_{ori}

$$L_{\text{ori}} = \|r_{\text{pred}} - r_{\text{true}}\|_2^2$$

- 加权损失 L_{total}

$$L_{\text{total}} = w_{\text{pos}}L_{\text{pos}} + w_{\text{ori}}L_{\text{ori}}$$

- FK 第二种损失函数:

- 整体 MSE 误差 L_{mse}

$$L_{\text{mse}} = \frac{1}{N} \sum_{i=1}^N \|y_{\text{pred}}^{(i)} - y_{\text{true}}^{(i)}\|_2^2$$

- IK考虑基于已训练的FK模型监督训练：当训练 IK 网络 $f_{\text{ik}}(x) \mapsto q_{\text{pred}}$ 且使用冻结的 FK_{ref} 将关节映射到末端位姿。

$$q_{\text{pred}} = f_{\text{ik}}(x), \quad y_{\text{fk}} = FK_{\text{ref}}(q_{\text{pred}})$$

- IK 第一种损失函数：

- 加权损失 L_{total}

$$L_{\text{total}} = w_{\text{pos}} \|p(y_{\text{fk}}) - p_{\text{true}}\|_2^2 + w_{\text{ori}} \|r(y_{\text{fk}}) - r_{\text{true}}\|_2^2$$

- IK 第二种损失函数：

- 整体 MSE 误差 L_{mse}

$$L_{\text{mse}} = \frac{1}{N} \sum_{i=1}^N \|y_{\text{fk}}^{(i)} - y_{\text{true}}^{(i)}\|_2^2$$

4. 训练超参与调度

- 优化器：Adam, weight_decay=1e-4;
- 学习率与调度：初始 lr=1e-3, 使用 CosineAnnealingLR 退火到 min_lr=1e-5;
- 训练轮次：FK/IK 均为 500 epoches;
- 提前停止：若验证集在 50 个 epoches 内不再提升则提前停止。

结果展示

对于 FK 和 IK 网络训练，均使用第二种损失函数，即整体 MSE 误差 L_{mse} 。我设计了一个对比试验，探究 IK 网络的输入数据和维度对网络精确性的影响。

1. FK 网络的输入选取 ['q1_sin', 'q1_cos', 'q2_sin', 'q2_cos', 'q3_sin', 'q3_cos', 'q4_sin', 'q4_cos', 'q5_sin', 'q5_cos'], IK 网络的输入选取['x', 'y', 'z', 'nx', 'ny', 'nz', 'ox', 'oy', 'oz', 'ax', 'ay', 'az'], 即 12 维的齐次变换矩阵 T ;

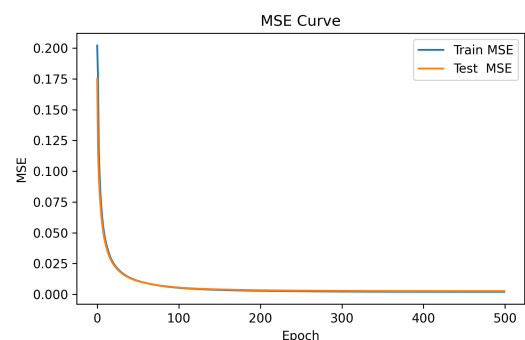
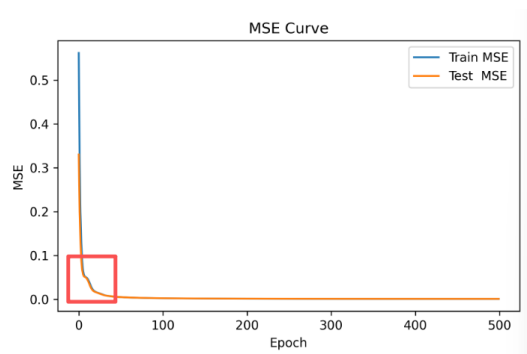


图 10 FK 训练曲线

图 11 IK 训练曲线

2. FK 网络的输入选取 ['q1_sin', 'q1_cos', 'q2_sin', 'q2_cos', 'q3_sin', 'q3_cos', 'q4_sin', 'q4_cos', 'q5_sin', 'q5_cos'], IK 网络的输入选取['x', 'y', 'z', 'roll_sin', 'roll_cos', 'pitch_sin', 'pitch_cos', 'yaw_sin', 'yaw_cos'], 即 9 维的 xyz+rpy;




图 12 FK 训练曲线




图 13 IK 训练曲线

3. FK 网络的输入选取 ['q1_sin', 'q1_cos', 'q2_sin', 'q2_cos', 'q3_sin', 'q3_cos', 'q4_sin', 'q4_cos', 'q5_sin', 'q5_cos'], IK 网络的输入选取['x', 'y', 'z', 'a', 'b', 'c', 'd'], 即 7 维的 xyz+abcd。




图 14 FK 训练曲线




图 15 IK 训练曲线

可以看出,

1. 三种 IK 输入下训练曲线单调下降并趋于稳定, 唯有输入为 12 维的齐次变换矩阵 T 时有些许波动;
2. IK 网络输入为 9 维的 xyz+rpy 时的 FK 训练曲线收敛最快;
3. IK 网络输入为 7 维的 xyz+abcd 时的 IK 训练曲线收敛最快。

任务六：模型验证

任务描述

调用训练得到的正逆运动学模型验证其预测结果, 以从仿真环境中读取到的关节角度 (或末端位姿) 为真值, 计算误差并分析原因。

任务实现

利用 `ModelValidator` 类计算模型误差，并绘误差制箱型图。

```
validator = ModelValidator(  
    fk_model_path, ik_model_path, stats_path,  
    input_keys_fk, output_keys_fk,  
    input_keys_ik, output_keys_ik,  
    hidden_layers_fk, hidden_layers_ik,  
)
```

- `fk_model_path` `ik_model_path` 是模型的路径；
- `input_keys_fk` `output_keys_fk` `input_keys_ik` `output_keys_ik` 是网络输入输出的数据和维度；
- `hidden_layers_fk` `hidden_layers_ik` 是隐藏层。

具体步骤如下：

1. FK 模型验证

- 生成 100 组随机关节角 `rand_q`；
- 利用 `ModelValidator` 类的 `validate_fk` 函数做正运动学模型验证。
 - 记录平均位置误差和最大位置误差
 - 绘制误差箱型图

2. IK 模型验证（12 维的齐次变换矩阵 T ）

- 生成 100 组随机末端姿态 `I9` 与 位置 `p`，拼接成 12 维的齐次变换矩阵 T ；
- 利用 `ModelValidator` 类的 `validate_ik` 函数做逆运动学模型验证。
 - 记录平均位置误差和最大位置误差
 - 绘制误差箱型图

3. IK 模型验证（9 维的 xyz+rpy）

- 生成 100 组随机末端位置 `x y z` 和偏转角 `roll pitch yaw`（取 sin/cos）；
- 利用 `ModelValidator` 类的 `validate_ik` 函数做逆运动学模型验证。
 - 记录平均位置误差和最大位置误差
 - 绘制误差箱型图

4. IK 模型验证（7 维的 xyz + abcd）

- 生成 100 组随机末端位置 `x y z` 和姿态 `a b b d`；
- 利用 `ModelValidator` 类的 `validate_ik` 函数做逆运动学模型验证。
 - 记录平均位置误差和最大位置误差
 - 绘制误差箱型图

注意: `ModelValidator` 类的 `validate_fk/ik` 函数内部需要统一误差计算方式, 即

- FK 验证直接调用 FK 模型预测并与仿真 FK 对应位置进行误差计算;
- IK 验证接收一批位姿, 调用 IK 模型生成预测关节, 然后通过 `PyBullet` 计算末端位置, 再进行误差计算。

结果展示

1. FK 网络的输入选取 `['q1_sin', 'q1_cos', 'q2_sin', 'q2_cos', 'q3_sin', 'q3_cos', 'q4_sin', 'q4_cos', 'q5_sin', 'q5_cos']`, IK 网路的输入选取 `['x', 'y', 'z', 'nx', 'ny', 'nz', 'ox', 'oy', 'oz', 'ax', 'ay', 'az']`, 即 12 维的齐次变换矩阵 T ;

- FK 平均位置误差: 119.10mm
- FK 最大位置误差: 341.15mm
- IK 平均位置误差: 159.07mm
- IK 最大位置误差: 406.70mm




图 16 FK 模型误差




图 17 IK 模型误差

2. FK 网络的输入选取 `['q1_sin', 'q1_cos', 'q2_sin', 'q2_cos', 'q3_sin', 'q3_cos', 'q4_sin', 'q4_cos', 'q5_sin', 'q5_cos']`, IK 网路的输入选取 `['x', 'y', 'z', 'roll_sin', 'roll_cos', 'pitch_sin', 'pitch_cos', 'yaw_sin', 'yaw_cos']`, 即 9 维的 xyz+rpy;

- FK 平均位置误差: 124.89mm
- FK 最大位置误差: 292.52mm
- IK 平均位置误差: 144.47mm
- IK 最大位置误差: 485.70mm




图 18 FK 模型误差




图 19 IK 模型误差

3. FK 网络的输入选取 `['q1_sin', 'q1_cos', 'q2_sin', 'q2_cos', 'q3_sin', 'q3_cos', 'q4_sin', 'q4_cos', 'q5_sin', 'q5_cos']`, IK 网路的输入选取 `['x', 'y', 'z', 'a', 'b', 'c', 'd']`, 即 7 维的 xyz+abcd。

- FK 平均位置误差：118.63mm
- FK 最大位置误差：305.79mm
- IK 平均位置误差：144.92mm
- IK 最大位置误差：495.43mm




图 20 FK 模型误差




图 21 IK 模型误差

可以看出，

1. IK 网络输入为 7 维的 xyz+abcd 时的 FK 平均误差最小；
2. IK 网络输入为 9 维的 xyz+rpv 时的 FK 最大误差最小；
3. IK 网络输入为 9 维的 xyz+rpv 时的 IK 平均误差最小；
4. IK 网络输入为 12 维的齐次变换矩阵 T 时的 IK 最大误差最小。

综上所述，结合模型收敛速度与模型精度，推荐 FK 网络的输入选取 ['q1_sin', 'q1_cos', 'q2_sin', 'q2_cos', 'q3_sin', 'q3_cos', 'q4_sin', 'q4_cos', 'q5_sin', 'q5_cos'], IK 网络的输入选取 ['x', 'y', 'z', 'roll_sin', 'roll_cos', 'pitch_sin', 'pitch_cos', 'yaw_sin', 'yaw_cos'], 进行训练，可以兼顾训练效率以及结果准确率。

误差分析

1. 训练数据集过小
 - 本次训练使用的是已有的数据集 `dofbot_fk_120000_norm.csv`;
 - 可以更换成更大的数据集如 `dofbot_fk_600000_norm.csv`;
2. 训练数据集覆盖不均匀
 - 由图 9 可以看出，数据集的稠密度随 Z 高度减小而减小，最底端的工作空间覆盖稍显不足；
 - 可以修改数据采集逻辑，使得工作点的稠密度分布均匀；
3. 模型层数大小
 - MLP 网络的隐藏层默认是 [100,30]，过小；
 - 本次训练更换成 [256,256,128]，模型精度提升；
4. 模型结构简单
 - MLP 网络默认 dropout=0.0，易过拟合，但训练过程中没有出现；
 - MLP 网络默认 activation='ReLU'，可考虑 LeakyReLU/GELU 作替代；

- MLP 网络默认 `block_type='res'` 且 `num_blocks=1`，即每个隐藏层后追加一个 ResBlock，可以提高网络深度表达能力；

5. FK 网络的输出/IK 网络的输入维度

- 由于 FK/IK 网络的输出并不完全解耦，例如 12 维的齐次变换矩阵 T 内部隐含耦合关系，所以维度的选择也会影响网络的精度；

6. 学习率过大

- `lr` 默认是 0.1，过大；
- 本次训练更换成 `1e-3`，模型精度提升；

7. 训练轮次不足

- `fk_epochs ik_epochs` 默认是 500；
- 本次训练中，FK/IK 网络均已收敛，没有影响；

8. 提前停止太激进

- `patience` 的容忍度默认是 50；
- 本次训练中，FK/IK 网络均未提前停止，没有影响。

任务七：仿真中物块的夹取与放置

任务描述

在 `PyBullet` 中，控制 Dofbot 机械臂完成物块抓取放置任务。

- 初始位置：(0.2, 0.1, 0)
- 初始欧拉角：(0, 0, $\pi/6$)
- 正方体物块尺寸：0.03
- 目标位置：(0.2, -0.1, 0)

任务实现

具体步骤如下：

1. 基于状态机控制思想，设计如下的 6 个状态：

```
PRE_GRASP_STATE = 0 # 预抓取状态
GRASP_STATE = 1 # 抓取状态
LIFT_STATE = 2 # 提起状态
MOVE_STATE = 3 # 移动状态
```

```
SET_STATE = 4      # 放置状态
BACK_STATE = 5     # 返回状态
```

2. 每个状态下机械臂的末端执行器位置和夹爪角度如下：

```
if current_state == PRE_GRASP_STATE:
    desired_pos = np.array(block_pos) + obj_offset_grasp
    gripper_angle = GRIPPER_DEFAULT_ANGLE
elif current_state == GRASP_STATE:
    desired_pos = np.array(block_pos) + obj_offset_grasp
    gripper_angle = GRIPPER_CLOSE_ANGLE
elif current_state == LIFT_STATE:
    desired_pos = np.array(block_pos) + obj_offset_move
    gripper_angle = GRIPPER_CLOSE_ANGLE
elif current_state == MOVE_STATE:
    desired_pos = np.array(target_pos) + obj_offset_move
    gripper_angle = GRIPPER_CLOSE_ANGLE
elif current_state == SET_STATE:
    desired_pos = np.array(target_pos) + obj_offset_set
    gripper_angle = GRIPPER_CLOSE_ANGLE
else: # BACK_STATE
    desired_pos = np.array(target_pos) + obj_offset_move
    gripper_angle = GRIPPER_DEFAULT_ANGLE
```

3. 利用 `env` 类中的逆运动学求解函数 `dofbot_setInverseKine` 将相应末端执行器位置转化为机械臂的关节角度。

```
jointPoses, _ = env.dofbot_setInverseKine(desired_pos.tolist(), orn=None)
```

- 注意：机械臂的动作空间只有 5 维，而物块的初始状态有 6 维，所以逆运动学会出现无解的情况。因此，这里只用 3 维的位置信息作逆运动学！！

4. 利用 `env` 类中的控制函数 `dofbot_control` 控制机械臂的关节和夹爪到达目标角度。

```
env.dofbot_control(jointPoses, gripper_angle)
```

5. 当机械臂末端执行器到达目标位置的帧数 / 夹爪接触物块的帧数 / 物块稳定的帧数大于阈值时，进行状态切换：

```
if current_state == PRE_GRASP_STATE and arrive_cnt >= STABLE_FRAMES:
    current_state = GRASP_STATE
    arrive_cnt = grip_cnt = settle_cnt = 0
elif current_state == GRASP_STATE and grip_cnt >= STABLE_FRAMES:
    current_state = LIFT_STATE
    arrive_cnt = grip_cnt = settle_cnt = 0
elif current_state == LIFT_STATE and arrive_cnt >= STABLE_FRAMES:
    current_state = MOVE_STATE
    arrive_cnt = grip_cnt = settle_cnt = 0
```

```

elif current_state == MOVE_STATE and arrive_cnt >= STABLE_FRAMES:
    current_state = SET_STATE
    arrive_cnt = grip_cnt = settle_cnt = 0
elif current_state == SET_STATE and settle_cnt >= RELEASE_STABLE_FRAMES:
    current_state = BACK_STATE
    arrive_cnt = grip_cnt = settle_cnt = 0
elif current_state == BACK_STATE and arrive_cnt >= STABLE_FRAMES:
    Reward = env.reward()

```

结果展示




图 22 仿真中物块的夹取与放置

拓展任务

任务描述

基于 解析 + MLP拟合残差 的方案实现正运动学建模，并用该模型监督逆运动学模型的训练，对比验证精度。

任务实现

与 任务五：模型训练 相比，本任务仅修改 FK 的损失函数。

记解析模型对第 i 个样本的预测为 $y_{\text{ana}}^{(i)}$ ，MLP 学习残差 $r_{\theta}(q^{(i)})$ ，复合预测为

$$y_{\text{pred}}^{(i)} = y_{\text{ana}}^{(i)} + r_{\theta}(q^{(i)}).$$

因此等价地，训练目标是让残差预测逼近真实残差 $r^{(i)} = y_{\text{true}}^{(i)} - y_{\text{ana}}^{(i)}$ ，采用均方误差可写为：

$$L_{\text{res}} = \frac{1}{N} \sum_{i=1}^N \left\| y_{\text{ana}}^{(i)} + r_{\theta}(q^{(i)}) - y_{\text{true}}^{(i)} \right\|_2^2 = \frac{1}{N} \sum_{i=1}^N \left\| r_{\theta}(q^{(i)}) - (y_{\text{true}}^{(i)} - y_{\text{ana}}^{(i)}) \right\|_2^2.$$

- 训练目标仍是令最终复合预测 $y_{\text{ana}} + r_{\theta}$ 与真实值一致；
- 将训练放到残差空间（MLP 只需学习小尺度误差），更易收敛且样本效率更高。

结果展示

FK 网络的输入选取 ['q1_sin', 'q1_cos', 'q2_sin', 'q2_cos', 'q3_sin', 'q3_cos', 'q4_sin', 'q4_cos', 'q5_sin', 'q5_cos'], IK 网路的输入选取['x', 'y', 'z', 'nx', 'ny', 'nz', 'ox', 'oy', 'oz', 'ax', 'ay', 'az'], 即 12 维的齐次变换矩阵 T 。




图 23 FK 训练曲线

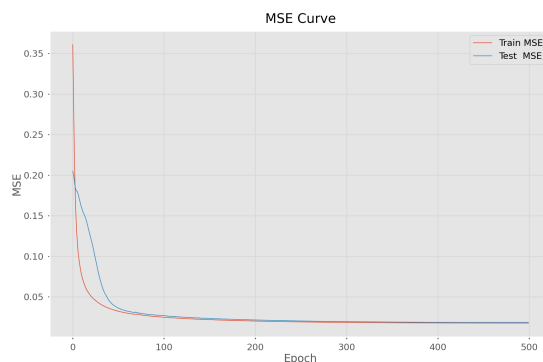


图 24 IK 训练曲线

- FK 平均位置误差: 121.88mm
- FK 最大位置误差: 396.17mm
- IK 平均位置误差: 135.50mm
- IK 最大位置误差: 386.86mm




图 20 FK 模型误差




图 21 IK 模型误差

可以看出, 虽然 解析 + MLP拟合残差 方案的 FK 模型误差并未显著优于 纯 MLP 方案, 但其监督下训练得到的 IK 模型误差更低。